

Estado del Arte sobre Ingeniería de Datos, Analítica de Datos y Visualización de Datos

Juan Diego Villamagua

*Carrera de Computación, Universidad Técnica Particular de Loja
Loja, Ecuador*

Resumen- La transformación digital ha consolidado a los datos como un recurso estratégico para organizaciones públicas y privadas. En este contexto, la ingeniería de datos permite construir infraestructuras para recolectar, integrar, procesar y almacenar información; la analítica de datos transforma esa información en conocimiento accionable; y la visualización de datos comunica hallazgos mediante representaciones comprensibles para usuarios técnicos y no técnicos [1]-[3].

Palabras clave- *ingeniería de datos, analítica de datos, visualización de datos, Big Data, inteligencia de negocios, calidad de datos.*

Abstract- Digital transformation has positioned data as a strategic organizational asset. This paper reviews the state of the art in data engineering, data analytics, and data visualization, emphasizing data architectures, data quality, analytical methods, interactive visualization, and emerging trends such as stream processing, lakehouse architectures, and MLOps [1]-[3].

Keywords- *data engineering, data analytics, data visualization, Big Data, business intelligence, data quality.*

I. INTRODUCCIÓN

La generación masiva de datos a partir de sistemas transaccionales, sensores, plataformas digitales y aplicaciones móviles ha incrementado la complejidad de capturar, almacenar y procesar información útil para la toma de decisiones. La literatura sobre Big Data sostiene que el valor de los datos no depende únicamente del volumen, sino también de la capacidad de integrarlos, depurarlos, analizarlos e interpretarlos dentro de procesos organizacionales [1], [2].

La ingeniería de datos se ha consolidado como la base técnica que permite convertir fuentes heterogéneas en activos confiables. Su campo de acción incluye pipelines de extracción, transformación y carga, almacenamiento escalable, procesamiento distribuido, control de calidad y disponibilidad de datos para procesos analíticos posteriores [3], [4].

La analítica de datos y la visualización complementan esta base al facilitar el descubrimiento de patrones, la construcción de modelos descriptivos y predictivos, y la comunicación de resultados mediante gráficos, tableros e interfaces interactivas. En consecuencia, las tres áreas deben analizarse de manera integrada, porque la visualización depende de datos preparados correctamente y la analítica pierde valor si sus resultados no son interpretables [5], [6].

II. METODOLOGÍA DE REVISIÓN

Este estado del arte se elaboró mediante una revisión narrativa y conceptual de artículos científicos y trabajos de conferencia relacionados con ingeniería de datos, analítica de datos, Big Data, calidad de datos, aprendizaje automático y visualización interactiva. La revisión priorizó aportes con alta relevancia académica y técnica, siguiendo la recomendación de organizar la literatura por conceptos y no solo por herramientas o productos comerciales [7], [8].

La selección bibliográfica se orientó a fuentes revisadas por pares o publicadas en conferencias y revistas reconocidas en computación, sistemas de información, bases de datos,

aprendizaje automático y visualización. Por esta razón, se reemplazaron referencias de páginas web institucionales por artículos científicos y se eliminaron tablas centradas en herramientas, ya que el objetivo de un estado del arte es explicar fundamentos, enfoques y tendencias, no listar tecnologías de manera descriptiva [7], [8].

III. INGENIERÍA DE DATOS

A. Arquitecturas y flujo de datos

La ingeniería de datos se ocupa de diseñar arquitecturas que permitan mover datos desde fuentes operacionales hacia repositorios analíticos de forma controlada. Estas arquitecturas consideran ingestión, limpieza, integración, transformación, almacenamiento y servicio de datos, de manera que los usuarios y sistemas analíticos accedan a información consistente y oportuna [1], [3].

Los pipelines de datos representan uno de los componentes centrales de esta disciplina, porque automatizan el tránsito desde datos crudos hasta conjuntos preparados para análisis. En la práctica, estos flujos deben manejar datos estructurados, semiestructurados y no estructurados, además de conservar trazabilidad sobre transformaciones, dependencias y errores durante el procesamiento [3], [4].

B. Calidad, integración y confiabilidad

La calidad de datos no se limita a la exactitud, sino que también incluye dimensiones como completitud, consistencia, actualidad, accesibilidad y relevancia para el usuario. Esta visión es importante porque una organización puede disponer de grandes volúmenes de información y, aun así, obtener decisiones deficientes si los datos no son confiables o no responden al contexto de uso [4].

La integración de fuentes heterogéneas exige resolver diferencias de formato, semántica, periodicidad y granularidad. Por ello, la ingeniería de datos no debe entenderse únicamente como programación de cargas, sino como un proceso de diseño que garantiza que los datos sean

interpretables, gobernables y reutilizables en distintos escenarios analíticos [1], [4].

C. Procesamiento distribuido y en tiempo real

El procesamiento distribuido surgió como respuesta a los límites de los sistemas tradicionales frente al crecimiento de los datos. Marcos de computación como Spark demostraron la relevancia de integrar cargas de trabajo por lotes, consultas interactivas, aprendizaje automático y procesamiento de flujos bajo un motor unificado y escalable [9].

El procesamiento en tiempo real añade nuevos retos, como baja latencia, tolerancia a fallos, gestión de estado y consistencia temporal. Los sistemas de streaming muestran que la utilidad de los datos aumenta cuando las organizaciones pueden actuar sobre eventos recientes y no solamente sobre información histórica procesada por lotes [10].

Las arquitecturas lakehouse constituyen una tendencia reciente que busca unificar capacidades de data warehouses y data lakes. Su importancia radica en reducir duplicaciones, mejorar el soporte para analítica avanzada y aprendizaje automático, y trabajar con formatos abiertos que faciliten interoperabilidad y escalabilidad [11].

IV. ANALÍTICA DE DATOS

A. De los datos al conocimiento

La analítica de datos se relaciona con el proceso de transformar datos en conocimiento mediante técnicas estadísticas, minería de datos y aprendizaje automático. Desde la perspectiva de descubrimiento de conocimiento en bases de datos, el análisis no inicia en el modelo, sino en la comprensión del dominio, la preparación de datos, la selección de patrones y la evaluación de resultados [13].

La analítica descriptiva resume lo ocurrido, la diagnóstica explica posibles causas, la predictiva estima comportamientos futuros y la prescriptiva propone acciones. Esta clasificación permite ubicar los métodos analíticos según su finalidad, aunque en proyectos reales estas categorías suelen combinarse dentro de un mismo flujo de trabajo [13], [14].

B. Métodos y modelos analíticos

Los métodos de agrupamiento, clasificación, regresión y detección de anomalías permiten identificar relaciones y patrones en conjuntos de datos. En particular, el clustering ha sido estudiado como una técnica clave para organizar observaciones similares cuando no existen etiquetas previas, lo que resulta útil en segmentación, exploración y análisis inicial [12].

Los modelos supervisados han evolucionado hacia métodos escalables capaces de trabajar con grandes volúmenes de datos y características de alta dimensionalidad. Algoritmos de ensamble como XGBoost evidencian cómo la optimización computacional, el manejo de datos dispersos y la regularización pueden mejorar el rendimiento predictivo en escenarios aplicados [13].

La literatura también muestra que el desempeño de los modelos depende de la disponibilidad de datos suficientes y

representativos. Por ello, la analítica moderna no puede separarse de la ingeniería de datos: mejores modelos requieren datos preparados, documentados y alineados con el problema que se desea resolver [14].

C. Limitaciones y riesgos

El uso de analítica avanzada presenta riesgos cuando se ignoran sesgos, datos incompletos o supuestos metodológicos no verificados. Un resultado estadístico puede parecer preciso y, al mismo tiempo, ser poco útil si no se valida con criterios del dominio, métricas adecuadas y análisis de calidad de los datos [4], [13].

Además, el despliegue de modelos en ambientes reales introduce costos de mantenimiento, dependencia de datos, cambios de distribución y deuda técnica. Estos aspectos explican por qué la analítica debe acompañarse de monitoreo, trazabilidad y procesos de actualización continua, especialmente cuando se aplica aprendizaje automático en producción [15].

V. VISUALIZACIÓN DE DATOS

A. Comunicación visual de información

La visualización de datos permite representar información compleja mediante codificaciones visuales que facilitan la identificación de tendencias, relaciones, valores atípicos y patrones. Su aporte principal consiste en apoyar el razonamiento humano, especialmente cuando los datos son numerosos o tienen múltiples dimensiones [6].

La visualización no debe reducirse a la creación de gráficos atractivos; debe responder a objetivos analíticos claros, seleccionar representaciones adecuadas y evitar distorsiones. La elección entre gráficos de barras, líneas, dispersión, mapas o redes depende del tipo de dato, la tarea del usuario y la relación que se desea comunicar [6], [16].

B. Interactividad y análisis visual

La interactividad amplía el valor de la visualización al permitir filtrar, ordenar, seleccionar, navegar, coordinar vistas y registrar hallazgos durante el análisis. Estas acciones convierten al usuario en parte activa del proceso de descubrimiento, lo que resulta especialmente útil en exploración de datos y análisis de decisiones [17].

La literatura en tareas de visualización plantea que una herramienta visual debe analizarse en función de qué quiere lograr el usuario, por qué necesita esa información y cómo interactúa con la representación. Esta perspectiva evita diseñar visualizaciones aisladas del contexto y favorece soluciones centradas en tareas analíticas reales [18].

C. Relación con inteligencia de negocios

En inteligencia de negocios, los tableros de control integran métricas, filtros e indicadores para apoyar decisiones operativas y estratégicas. Sin embargo, su utilidad depende de que exista coherencia entre el modelo de datos, la pregunta de negocio y el diseño visual, porque una visualización clara no puede compensar datos mal definidos o indicadores ambiguos [6], [17].

Una buena visualización debe equilibrar precisión, simplicidad e interpretación. Esto implica evitar sobrecarga visual, mantener escalas adecuadas, mostrar unidades y contexto, y permitir que el lector identifique rápidamente el mensaje principal sin perder la posibilidad de explorar detalles relevantes [16], [18].

VI. TENDENCIAS ACTUALES

Una tendencia relevante es la convergencia entre ingeniería de datos, ciencia de datos y operaciones de aprendizaje automático. En sistemas reales, el modelo predictivo representa solo una parte del producto; también se requieren datos confiables, pipelines reproducibles, pruebas, monitoreo y mecanismos para controlar cambios en producción [15], [19].

El enfoque MLOps surge para operacionalizar modelos de aprendizaje automático mediante prácticas, roles y arquitecturas que conectan desarrollo, despliegue y monitoreo. Esta tendencia exige que los profesionales comprendan tanto modelos analíticos como infraestructura de datos, automatización y gobierno del ciclo de vida [20].

Otra tendencia es el uso de arquitecturas abiertas y escalables para soportar analítica avanzada, consultas interactivas y entrenamiento de modelos sobre grandes repositorios. En este escenario, los lakehouse y los motores distribuidos buscan reducir la fragmentación entre almacenamiento, procesamiento y consumo analítico [9], [11].

Finalmente, la visualización interactiva continuará integrándose con analítica avanzada para facilitar explicabilidad, exploración y comunicación de resultados. Esta integración es necesaria porque las organizaciones requieren no solo predicciones, sino también evidencia comprensible para justificar decisiones y detectar problemas en los datos o modelos [17], [18].

VII. DISCUSIÓN

El análisis de la literatura muestra que la ingeniería de datos, la analítica y la visualización no deben abordarse como áreas separadas. La ingeniería garantiza disponibilidad y calidad; la analítica produce patrones, métricas y modelos; y la visualización convierte los resultados en conocimiento comunicable para la toma de decisiones [1], [4], [17].

A diferencia de un listado de herramientas, un estado del arte debe explicar conceptos, problemas técnicos, enfoques metodológicos y tendencias de investigación. Por ello, resulta más pertinente discutir pipelines, calidad, escalabilidad, modelos, interacción y gobierno de datos que presentar tablas extensas sobre tecnologías específicas [3], [7], [8].

En el contexto educativo y profesional, dominar estas áreas permite construir soluciones basadas en datos con mayor rigor. Un proyecto sólido debe iniciar con preguntas claras, continuar con datos confiables, aplicar métodos adecuados y finalizar con visualizaciones que comuniquen hallazgos de forma comprensible y verificable [5], [6], [18].

VIII. CONCLUSIONES

La ingeniería de datos constituye la base de los ecosistemas analíticos modernos, porque permite integrar fuentes diversas, asegurar calidad y preparar información para consultas, reportes y modelos. Sin esta base, los procesos de analítica y visualización quedan expuestos a errores, inconsistencias y baja confiabilidad [1], [4].

La analítica de datos aporta métodos para convertir información en conocimiento, desde resúmenes descriptivos hasta modelos predictivos. No obstante, su efectividad depende de la calidad de los datos, de la correcta interpretación del dominio y de la evaluación continua de los resultados obtenidos [5], [13], [15].

La visualización de datos cumple una función esencial en la comunicación de resultados, ya que traduce análisis complejos en representaciones que apoyan la comprensión y la decisión. Su diseño debe responder a tareas concretas, criterios de claridad y principios de interacción que faciliten la exploración responsable de la información [6], [17], [18].

Las tendencias actuales apuntan hacia arquitecturas lakehouse, procesamiento distribuido, streaming, MLOps y visualizaciones interactivas conectadas con analítica avanzada. En conjunto, estas líneas reflejan que el futuro de los datos no dependerá solo de herramientas, sino de la integración rigurosa entre infraestructura, método, calidad y comunicación [9], [11], [20].

REFERENCIAS

- [1] H. V. Jagadish, J. Gehrke, A. Labrinidis, Y. Papakonstantinou, J. M. Patel, R. Ramakrishnan, and C. Shahabi, "Big Data and Its Technical Challenges," *Communications of the ACM*, vol. 57, no. 7, pp. 86-94, Jul. 2014, doi: 10.1145/2611567.
- [2] A. Labrinidis and H. V. Jagadish, "Challenges and Opportunities with Big Data," *Proceedings of the VLDB Endowment*, vol. 5, no. 12, pp. 2032-2033, 2012, doi: 10.14778/2367502.2367572.
- [3] C. L. P. Chen and C.-Y. Zhang, "Data-Intensive Applications, Challenges, Techniques and Technologies: A Survey on Big Data," *Information Sciences*, vol. 275, pp. 314-347, 2014, doi: 10.1016/j.ins.2014.01.015.
- [4] R. Y. Wang and D. M. Strong, "Beyond Accuracy: What Data Quality Means to Data Consumers," *Journal of Management Information Systems*, vol. 12, no. 4, pp. 5-33, 1996, doi: 10.1080/07421222.1996.11518099.
- [5] U. Fayyad, G. Piatetsky-Shapiro, and P. Smyth, "From Data Mining to Knowledge Discovery in Databases," *AI Magazine*, vol. 17, no. 3, pp. 37-54, 1996, doi: 10.1609/aimag.v17i3.1230.
- [6] D. A. Keim, "Information Visualization and Visual Data Mining," *IEEE Transactions on Visualization and Computer Graphics*, vol. 8, no. 1, pp. 1-8, 2002, doi: 10.1109/2945.981847.
- [7] J. Webster and R. T. Watson, "Analyzing the Past to Prepare for the Future: Writing a Literature Review," *MIS Quarterly*, vol. 26, no. 2, pp. xiii-xxiii, 2002.
- [8] Y. Levy and T. J. Ellis, "A Systems Approach to Conduct an Effective Literature Review in Support of Information Systems Research," *Informing Science: The International Journal of an Emerging Transdiscipline*, vol. 9, pp. 181-212, 2006, doi: 10.28945/479.
- [9] M. Zaharia et al., "Apache Spark: A Unified Engine for Big Data Processing," *Communications of the ACM*, vol. 59, no. 11, pp. 56-65, Nov. 2016, doi: 10.1145/2934664.
- [10] T. Akidau et al., "MillWheel: Fault-Tolerant Stream Processing at Internet Scale," *Proceedings of the VLDB Endowment*, vol. 6, no. 11, pp. 1033-1044, 2013, doi: 10.14778/2536222.2536229.

- [11] M. Armbrust, A. Ghodsi, R. Xin, and M. Zaharia, "Lakehouse: A New Generation of Open Platforms that Unify Data Warehousing and Advanced Analytics," in Proc. 11th Conference on Innovative Data Systems Research (CIDR), 2021.
- [12] A. K. Jain, M. N. Murty, and P. J. Flynn, "Data Clustering: A Review," ACM Computing Surveys, vol. 31, no. 3, pp. 264-323, 1999, doi: 10.1145/331499.331504.
- [13] T. Chen and C. Guestrin, "XGBoost: A Scalable Tree Boosting System," in Proc. 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2016, pp. 785-794, doi: 10.1145/2939672.2939785.
- [14] A. Halevy, P. Norvig, and F. Pereira, "The Unreasonable Effectiveness of Data," IEEE Intelligent Systems, vol. 24, no. 2, pp. 8-12, 2009, doi: 10.1109/MIS.2009.36.
- [15] D. Sculley et al., "Hidden Technical Debt in Machine Learning Systems," in Advances in Neural Information Processing Systems, 2015, pp. 2503-2511.
- [16] J. Heer, M. Bostock, and V. Ogievetsky, "A Tour through the Visualization Zoo," Communications of the ACM, vol. 53, no. 6, pp. 59-67, 2010, doi: 10.1145/1743546.1743567.
- [17] J. Heer and B. Shneiderman, "Interactive Dynamics for Visual Analysis," Communications of the ACM, vol. 55, no. 4, pp. 45-54, 2012, doi: 10.1145/2133806.2133821.
- [18] M. Brehmer and T. Munzner, "A Multi-Level Typology of Abstract Visualization Tasks," IEEE Transactions on Visualization and Computer Graphics, vol. 19, no. 12, pp. 2376-2385, 2013, doi: 10.1109/TVCG.2013.124.
- [19] N. Polyzotis, S. Roy, S. E. Whang, and M. Zinkevich, "Data Management Challenges in Production Machine Learning," in Proc. ACM SIGMOD International Conference on Management of Data, 2017, pp. 1723-1726, doi: 10.1145/3035918.3054782.
- [20] D. Kreuzberger, N. Kühl, and S. Hirschl, "Machine Learning Operations (MLOps): Overview, Definition, and Architecture," IEEE Access, vol. 11, pp. 31866-31879, 2023, doi: 10.1109/ACCESS.2023.3262138.