

Estructura propuesta del proyecto

Reto Final Datos — Macroentorno Ecuador

Objetivo


Proponer una estructura clara de carpetas, módulos, scripts SQL y documentación para construir el pipeline de datos del macroentorno ecuatoriano la propuesta se enfoca únicamente en el alcance de 6to ciclo: PostgreSQL, los tres bloques de fuentes, mínimo doce tablas Silver, vistas Gold base más dos adicionales, integración con RPA, dashboard de tres páginas y documentación técnica.

Elemento exigido para 6to ciclo	Cómo lo cubre la estructura propuesta
PostgreSQL como base de datos	La carpeta database/ contiene DDL, creación de tablas, vistas, roles y consultas de validación pensadas para PostgreSQL.
Tres bloques completos de fuentes	data/raw/ y src/transform/ separan BCE, INEC, Supercias y MINEDUC para procesar todas las fuentes del reto.
Mínimo doce tablas Silver	database/sql/01_create_silver_tables.sql define dimensiones y hechos suficientes para BCE, INEC, Supercias y MINEDUC.
Vistas Gold + dos adicionales	database/sql/02_create_gold_views.sql contiene las vistas obligatorias y dos vistas propuestas para análisis estratégico UTPL.
Pipeline automático con RPA	src/watchers/ y src/pipeline.py detectan archivos nuevos en data/raw/rpa_inbox/ y ejecutan el procesamiento.
Dashboard de tres páginas	dashboard/powerbi/ guarda el .pbix y un README con la conexión a vistas Gold.
Informe técnico y acuerdos	docs/ contiene arquitectura, ER, decisiones de limpieza, acuerdo RPA y análisis ejecutivo.

1. Estructura general recomendada

datos_macroentorno_6to/

```
├── README.md
├── requirements.txt
├── .env.example
├── .gitignore
├── data/
│   ├── raw/
│   │   ├── manual/
│   │   │   ├── bce/
│   │   │   ├── inec/
│   │   │   ├── supercias/
│   │   │   └── mineduc/
│   │   └── rpa_inbox/
│   ├── bronze/
│   ├── rejected/
│   └── catalog/
└── database/
```



2. Para qué sirve cada carpeta y qué cumple

Elemento	Función	Cumplimiento en el proyecto
README.md	Explica cómo instalar, configurar y ejecutar el proyecto.	Entregable de repositorio GitHub privado con instrucciones claras.
requirements.txt	Lista librerías de Python: pandas, openpyxl, sqlalchemy, psycopg2, python-dotenv, watchdog, etc.	Permite reproducibilidad del entorno.
.env.example	Plantilla de variables: host, puerto, usuario, contraseña y nombre de BD.	Evita quemar credenciales en el código.
data/raw/manual/	Guarda archivos descargados manualmente en semanas 1 a 4.	Permite avanzar antes de recibir archivos automáticos.
data/raw/rpa_inbox/	Carpeta donde RPA deposita archivos	Cumple la integración con RPA y el

	desde semana 5.	reprocesamiento automático.
data/bronze/	Copia controlada de archivos crudos ya recibidos.	Representa la capa Bronze del modelo medallón.
data/rejected/	Archivos con estructura incorrecta o errores de validación.	Documenta fallos y evita contaminar la base.
data/catalog/	Diccionario de fuentes, nombres esperados y columnas clave.	Ayuda a controlar el formato fuente + fecha acordado con RPA.
database/sql/	Scripts DDL, vistas Gold, validaciones y permisos.	Cumple modelo relacional, FK, vistas y PostgreSQL.
database/er/	Diagrama entidad-relación exportado como imagen o PDF.	Cumple el primer entregable aprobado por el tutor.
src/extract/	Lee Excel, CSV y carpetas de entrada.	Separa la extracción de las transformaciones.
src/transform/	Limpia y normaliza cada bloque: BCE, INEC, Supercias y MINEDUC.	Cumple decisiones de limpieza: nullos, duplicados, tipos y normalización.
src/load/	Carga DataFrames a PostgreSQL en tablas Silver.	Cumple carga correcta de tablas Silver.
src/gold/	Ejecuta o refresca las vistas Gold y validaciones de indicadores.	Conecta Silver con el dashboard.
src/watchers/	Detecta archivos nuevos en rpa_inbox.	Cumple procesamiento automático sin intervención manual.
dashboard/powerbi/	Archivo .pbix y notas de conexión a PostgreSQL.	Cumple dashboard de tres páginas con KPIs y filtros.
docs/	Arquitectura, limpieza, integración RPA, análisis e informe final.	Cumple documentación, acuerdo RPA y presentación final.
tests/	Pruebas simples para transformaciones y carga.	Reduce errores antes de la demo.
logs/	Registra ejecuciones, errores, archivos procesados y fecha.	Sirve como evidencia en la demostración.

3. Estructura de módulos Python

Archivo	Responsabilidad sugerida
src/config.py	Leer variables de .env y rutas del proyecto.
src/db.py	Crear conexión a PostgreSQL con SQLAlchemy y probar conectividad.
src/pipeline.py	Orquestar extracción, transformación, carga, actualización Gold y registro en logs.
src/extract/readers.py	Funciones genéricas para read_excel(), read_csv(), encoding latin-1 y separador ;.
src/extract/file_registry.py	Registrar archivos procesados para no duplicar cargas.
src/transform/bce.py	Limpiar PIB real, PIB nominal, VAB, petróleo/riesgo país e IEE.
src/transform/inec.py	Normalizar ENEMDU con melt() y cargar Censo 2022 por CIU.
src/transform/supercias.py	Limpiar ranking y directorio de compañías, situación legal, provincia, cantón y CIU.
src/transform/mineduc.py	Limpiar AMIE 2023-2024, filtrar Bachillerato y último grado para bachilleres.
src/load/silver_loader.py	Insertar dimensiones y hechos Silver respetando claves y duplicados.

src/gold/run_gold_sql.py	Ejecutar SQL de vistas Gold o refrescar vistas materializadas.
src/watchers/rpa_watcher.py	Monitorear data/raw/rpa_inbox/ y disparar pipeline.py al detectar archivos nuevos.
src/utils/cleaning.py	Funciones comunes: normalizar nombres, convertir fechas, limpiar números, manejar nulos.
src/utils/logger.py	Guardar logs de ejecución y errores.

4. Modelo de datos Silver propuesto para 6to ciclo

Para cumplir el mínimo de doce tablas Silver, se propone separar dimensiones comunes y hechos por fuente esto facilita las relaciones, evita repetir provincias/cantones y permite conectar Power BI a vistas limpias.

Tabla Silver	Fuente	Uso principal
dim_tiempo	Común	Fecha, año, mes y trimestre.
dim_geografia	Común	Provincia, cantón y códigos.
dim_ciiu	Común	Rama o actividad económica.
fact_pib_real_anual	BCE	PIB real, población, PIB per cápita y variación.
fact_pib_nominal	BCE	PIB per cápita nominal en dólares corrientes.
fact_vab_provincia_industria	BCE	Valor agregado bruto por provincia, cantón y CIIU.
fact_petroleo_riesgo	BCE	Precio WTI y riesgo país diario.
fact_iee	BCE	Expectativas empresariales: global, comercio, construcción y manufactura.
fact_enemdu	INEC	Indicadores laborales normalizados por área nacional, urbana y rural.
fact_censo_ocupacion	INEC	Personas ocupadas por provincia, cantón, sexo, edad y CIIU.
fact_supercias_ranking	Supercias	Ingresos, activos, situación legal y CIIU de empresas.
fact_supercias_directorio	Supercias	Conteo de compañías activas por provincia y cantón.
fact_mineduc_amie	MINEDUC	Bachilleres por provincia, cantón, institución y sostenimiento.

5. Vistas Gold recomendadas

Vista Gold	Qué responde	Observación
gold_pib_tendencia	P1: evolución de la economía ecuatoriana.	Incluye clasificación del ciclo económico.
gold_empleo_tendencia	P2: evolución del desempleo o indicadores laborales.	Usa ENEMDU normalizada por periodo.
gold_petroleo_30dias	Contexto económico reciente.	Promedio móvil de WTI y riesgo país.
gold_empresas_provincia	P3: empresas activas e ingresos por provincia.	Se calcula desde Supercias.
gold_bachilleres_vs_empresas	P3: bachilleres frente a empresas por provincia.	Cruce estratégico MINEDUC + Supercias.
gold_productividad_vab_empleo	Vista adicional 6to ciclo.	Relaciona VAB provincial con

		personas ocupadas por CIIU.
gold_oportunidad_utpl_provincia	Vista adicional 6to ciclo.	Ranking estratégico: bachilleres altos, empresas bajas y brecha de oportunidad.

6. Dashboard: páginas, datos y análisis

Página	Visualizaciones sugeridas	Vistas conectadas
P1 Economía ecuatoriana	Línea de PIB real, barras de variación, KPI de PIB per cápita y variación interanual.	gold_pib_tendencia, gold_petroleo_30dias.
P2 Actividad económica y empleo	Mapa de VAB por provincia, barras top 10 por CIIU, KPI de desempleo reciente.	gold_empleo_tendencia, gold_productividad_vab_empleo.
P3 Bachilleres y empresas	Barras agrupadas, ratio bachilleres/empresas, ranking de provincias estratégicas.	gold_bachilleres_vs_empresas, gold_oportunidad_utpl_provincia.

7. Recomendación final de organización

La estructura debe mantenerse modular: cada fuente se limpia en su propio archivo, la base se construye con scripts SQL separados y el dashboard solo debe conectarse a vistas Gold, no a archivos Excel o CSV así el proyecto cumple el enfoque de 6to ciclo porque demuestra ingeniería de datos, modelado relacional, automatización, integración con RPA y análisis estratégico para la UTPL.