


UNIVERSIDAD TÉCNICA PARTICULAR DE LOJA
SISTEMA DE INTELIGENCIA DE NEGOCIOS PARA EL ANÁLISIS
EDUCATIVO EN ECUADOR

1. Introducción

El presente informe técnico describe el desarrollo de un proceso ETL (Extract, Transform and Load) aplicado a datos educativos del Ministerio de Educación del Ecuador (MINEDUC), utilizando herramientas de ingeniería y análisis de datos.

El proyecto tuvo como objetivo principal construir un flujo de integración de datos que permitiera extraer información desde un archivo CSV, transformarla mediante procesos de limpieza y modelado dimensional, almacenarla en una base de datos PostgreSQL y finalmente visualizarla en Power BI mediante dashboards interactivos.

A través de este proyecto se buscó aplicar conceptos relacionados con ingeniería de datos, inteligencia de negocios (BI), modelado dimensional y análisis visual de información educativa.



2. Objetivos

2.1 Objetivo General

Desarrollar un sistema de procesamiento y análisis de datos educativos mediante un proceso ETL y herramientas de Business Intelligence para generar información útil sobre la realidad educativa ecuatoriana.

2.2 Objetivos Específicos

- Extraer información desde un dataset educativo del MINEDUC.
- Realizar procesos de limpieza y transformación de datos.
- Diseñar un modelo dimensional para análisis BI.
- Almacenar la información en PostgreSQL.
- Construir dashboards interactivos en Power BI.
- Analizar indicadores educativos mediante visualizaciones.

3. Tecnologías Utilizadas

Tecnología	Descripción
Python	Lenguaje utilizado para el desarrollo del proceso ETL
Pandas	Librería utilizada para manipulación de datos
PostgreSQL	Sistema gestor de base de datos
SQLAlchemy	Conexión entre Python y PostgreSQL
Power BI	Herramienta de visualización y análisis BI
CSV	Fuente de datos educativa


4. Arquitectura del Proyecto

El flujo general del sistema desarrollado se basa en una arquitectura ETL compuesta por las siguientes etapas:

- Extracción de datos desde un archivo CSV.
- Transformación y limpieza de información.
- Construcción del modelo dimensional.
- Carga de información hacia PostgreSQL.
- Visualización de datos mediante Power BI.

La arquitectura implementada puede representarse de la siguiente manera:

CSV → Python ETL → PostgreSQL → Power BI



5. Desarrollo del Proceso ETL

5.1 Extracción de Datos

La extracción de datos se realizó desde un archivo CSV proporcionado por el MINEDUC. Para ello se utilizó la librería Pandas de Python mediante la función `read_csv()`.

Durante esta etapa se verificó:

- Correcta lectura del archivo.
- Integridad de columnas.
- Tipos de datos.
- Existencia de valores nulos.

5.2 Transformación de Datos

La etapa de transformación consistió en preparar los datos para su posterior análisis y almacenamiento. Durante esta fase se realizaron procesos de limpieza, normalización y construcción del modelo dimensional.

Procesos de limpieza aplicados

Proceso	Descripción
Eliminación de duplicados	Se eliminaron registros repetidos para evitar inconsistencias en el análisis.
Tratamiento de valores nulos	Se removieron registros con datos críticos faltantes.
Corrección de inconsistencias	Se estandarizaron nombres y formatos de información.
Normalización de columnas	Se ajustaron nombres de columnas para facilitar el procesamiento ETL.

pgAdmin 4

File Object Tools Edit View Window Help

Object Explorer

- Aggregates
- Collations
- Domains
- FTS Configurations
- FTS Dictionaries
- FTS Parsers
- FTS Templates
- Foreign Tables
- Functions
- Materialized Views
- Operators
- Procedures
- Sequences
- Tables (3)
 - dim_institucion
 - dim_ubicacion
 - fact_matricula
- Trigger Functions
- Types
- Views
- Subscriptions
- geoasistencia
- postgres
- talent_track
- tienda_tecnologia

Query

```
SELECT * FROM public.dim_institucion
ORDER BY cod_amie ASC
```

Data Output

	cod_amie [PK] character varying (20)	nombre_institucion text	sostenimiento character varying (50)	area character varying (20)
1	01B00002	UNIDAD EDUCATIVA PARTICULAR ROSA DE JESUS CORDERO	Particular	Urbana
2	01B00007	HUELLITAS CREATIVAS	Particular	Urbana
3	01B00010	CEBCI	Particular	Urbana
4	01B00014	BILINGUE INTEGRAL	Particular	Urbana
5	01B00019	CENTRO EDUCATIVO ROUSSEAU	Particular	Rural
6	01B00020	COLEGIO INTERCULTURAL BILINGUE DE NARANCAY	Fiscal	Rural
7	01B00021	SEIS DE JUNIO	Fiscal	Rural
8	01B00022	LA PAZ INTERCULTURAL BILINGUE AZUAY	Fiscal	Urbana

Servers > PostgreSQL 18 > Databases > amie_mineduc > Schemas > public > Tables > dim_institucion

pgAdmin 4

File Object Tools Edit View Window Help

Object Explorer

- Aggregates
- Collations
- Domains
- FTS Configurations
- FTS Dictionaries
- FTS Parsers
- FTS Templates
- Foreign Tables
- Functions
- Materialized Views
- Operators
- Procedures
- Sequences
- Tables (3)
 - dim_institucion
 - dim_ubicacion
 - fact_matricula
- Trigger Functions
- Types
- Views
- Subscriptions
- geoasistencia
- postgres
- talent_track
- tienda_tecnologia


Query

```
SELECT * FROM public.dim_ubicacion
ORDER BY id_ubicacion ASC
```

Data Output

	id_ubicacion [PK] integer	provincia character varying (100)	cod_provincia integer	canton character varying (100)	cod_canton integer	parroquia character varying (100)
1	1	AZUAY	1	CUENCA	101	EL SAGRARIO
2	2	AZUAY	1	CUENCA	101	MONAY
3	3	AZUAY	1	CUENCA	101	BAÑOS
4	4	AZUAY	1	CUENCA	101	CHAUCHA
5	5	AZUAY	1	CUENCA	101	GIL RAMIREZ DAVALOS
6	6	AZUAY	1	CUENCA	101	MOLLETURO
7	7	AZUAY	1	CUENCA	101	QUINGEO
8	8	AZUAY	1	CUENCA	101	RICARTE
9	9	AZUAY	1	CUENCA	101	SANTA ANA
10	10	AZUAY	1	CUENCA	101	TARQUI
11	11	AZUAY	1	CUENCA	101	TUPI
12	12	AZUAY	1	CUENCA	101	TUPI
13	13	AZUAY	1	GUALACEO	103	GUALACEO

Successfully run. Total query runtime: 510 msec. 1691 rows affected.



Tablas dimensionales construidas

Las tablas dimensionales fueron diseñadas para facilitar el análisis de la información educativa y mejorar el rendimiento de las consultas.

Tabla	Descripción	Campos principales
dim_ubicacion	Contiene información geográfica utilizada para segmentar los datos educativos.	provincia, canton, parroquia
dim_institucion	Contiene información descriptiva de las instituciones educativas.	cod_amie, nombre_institucion, sostenimiento, area, nivel_educacion
fact_matricula	Contiene las métricas principales utilizadas para el análisis educativo.	total_estudiantes, total_docentes, estudiantes_f, estudiantes_m, anio_lectivo

5.3 Carga de Datos

Una vez finalizada la transformación, la información fue cargada hacia PostgreSQL utilizando SQLAlchemy.

Las tablas creadas dentro de PostgreSQL se detallan a continuación:

Tabla	Función
dim_ubicacion	Almacena información geográfica para segmentación territorial.
dim_institucion	Almacena información descriptiva de instituciones educativas.
fact_matricula	Almacena métricas y datos estadísticos de matrícula.

Posteriormente se realizaron validaciones para garantizar la correcta integración de la información.

Validación	Descripción
Integridad de registros	Verificación de consistencia y completitud de datos cargados.
Relaciones entre tablas	Validación de claves y relaciones del modelo dimensional.
Correcta carga de datos	Confirmación de inserción exitosa en PostgreSQL.

6. Modelo Dimensional

El modelo dimensional implementado sigue un esquema tipo estrella.

La relación entre tablas es la siguiente:

- `dim_ubicacion` → `dim_institucion`
- `dim_institucion` → `fact_matricula`

Este modelo facilita:

- consultas analíticas
- generación de KPIs
- segmentación de información
- visualización BI




7. Dashboard en Power BI

Se desarrolló un dashboard interactivo en Power BI con el objetivo de analizar indicadores educativos del Ecuador.

El dashboard implementado incluye distintos componentes orientados al análisis visual de la información educativa.

Componente	Descripción
KPIs generales	Muestran métricas globales del sistema educativo.
Gráficos comparativos	Permiten comparar variables educativas entre provincias y niveles.
Tendencias temporales	Analizan la evolución histórica de la matrícula.
Segmentadores dinámicos	Facilitan el filtrado interactivo de información.
Análisis geográfico	Permite visualizar información por provincia y ubicación.



8. Indicadores Implementados

8.1 Total de Estudiantes

Representa la cantidad total de estudiantes registrados en el sistema educativo.

8.2 Total de Docentes

Muestra la cantidad total de docentes registrados.

8.3 Total de Instituciones

Indica la cantidad de instituciones educativas únicas.

8.4 Ratio Estudiante/Docente


Representa la cantidad promedio de estudiantes por docente.

Este indicador permite identificar posibles sobrecargas académicas.

9. Análisis de Resultados

9.1 Carga Docente por Provincia

Se identificaron provincias con mayores ratios de estudiantes por docente, evidenciando una posible sobrecarga educativa y necesidad de fortalecimiento del personal docente.




Interpretación

Las provincias con ratios más altos presentan mayor presión educativa y podrían requerir una mejor distribución de recursos docentes.

9.2 Brecha de Género en la Matrícula

Se realizó una comparación entre estudiantes hombres y mujeres según el nivel educativo.




Interpretación

Los resultados muestran diferencias en la participación masculina y femenina según el nivel educativo, evidenciando posibles brechas de acceso o permanencia.

9.3 Evolución de la Matrícula en Loja

Se analizó la evolución histórica de la matrícula estudiantil en la provincia de Loja entre 2015 y 2024.



Interpretación

La matrícula presenta variaciones a lo largo de los años lectivos, lo que permite analizar cambios en la demanda educativa y posibles factores externos asociados.

10. Conclusiones

- El proceso ETL permitió integrar y transformar correctamente los datos educativos.
- PostgreSQL facilitó el almacenamiento estructurado de la información.
- El modelo dimensional permitió optimizar el análisis y visualización de datos.
- Power BI permitió generar dashboards interactivos y KPIs educativos.
- El análisis desarrollado facilita la toma de decisiones basadas en datos.

11. Recomendaciones

- Incorporar más años lectivos para ampliar el análisis histórico.
- Implementar automatización del proceso ETL.
- Integrar nuevas variables socioeconómicas.
- Desarrollar dashboards adicionales orientados a rendimiento académico.
- Implementar actualización periódica de datos.

12. Bibliografía

Referencias

- McKinney, W. (2022). *Python for data analysis: Data wrangling with pandas, NumPy, and Jupyter* (3.a ed.). O'Reilly Media.

- Microsoft. (2024). *Power BI documentation*. Microsoft Learn.
<https://learn.microsoft.com/power-bi/>
- Ministerio de Educación del Ecuador. (2024). *Datos abiertos de instituciones educativas*. Gobierno del Ecuador. <https://educacion.gob.ec/datos-abiertos/>
- PostgreSQL Global Development Group. (2024). *PostgreSQL documentation*. PostgreSQL. <https://www.postgresql.org/docs/>
- Python Software Foundation. (2024). *Python documentation*. Python.org.
<https://docs.python.org/3/>
- SQLAlchemy Authors. (2024). *SQLAlchemy documentation*. SQLAlchemy.
<https://docs.sqlalchemy.org/>
- Wes McKinney. (2023). *pandas documentation*. pandas.pydata.org.
<https://pandas.pydata.org/docs/>